ML for NLP Project : Comparaison de méthodes de NLP pour la classification de textes politiques selon leur orientation idéologique

Rouch Valentin

Abstract

Ce projet s'inscrit dans le cadre de la classification automatique de textes politiques selon leur orientation idéologique. L'objectif est de prédire l'appartenance d'un document à l'une des trois classes suivantes : *gauche*, *centre* ou *droite*.

Pour répondre à cette problématique, plusieurs approches de traitement automatique du langage naturel ont été explorées et comparées, allant de méthodes classiques basées sur TF-IDF à des modèles plus récents reposant sur des représentations sémantiques, tels que Doc2Vec et SBERT.

Les résultats montrent que l'approche TF-IDF associée à un classifieur linéaire offre les meilleures performances, suggérant que la tâche repose principalement sur des indices lexicaux explicites. À l'inverse, les modèles exploitant des représentations sémantiques plus complexes n'apportent pas d'amélioration significative dans ce contexte.

Enfin, plusieurs limites ont été identifiées, notamment liées à la qualité de la labellisation, au déséquilibre des classes et aux contraintes de calcul. Des pistes d'amélioration sont proposées afin d'augmenter la robustesse et les performances des modèles.

1 Introduction

La classification automatique de textes constitue une tâche centrale en traitement automatique du langage naturel (NLP), avec de nombreuses applications telles que l'analyse d'opinion, la catégorisation de documents ou encore la détection de biais politiques. Dans ce projet, nous nous intéressons à la classification de textes politiques selon leur orientation idéologique.

Plus précisément, l'objectif est de prédire l'appartenance d'un document à l'une des trois catégories suivantes : *gauche*, *centre* ou *droite*.

Afin de répondre à cette problématique, nous avons exploré et comparé plusieurs approches de modélisation issues du NLP, allant de méthodes classiques à base de représentations vectorielles (TF-IDF et Doc2Vec) à une approche plus récente basée sur un modèle de type Transformer (SBERT).

L'objectif de ce travail est double. Il s'agit d'une part d'évaluer les performances de différentes approches sur une même tâche de classification, et d'autre part d'analyser leurs forces et leurs limites, notamment en ce qui concerne la gestion des textes longs et la capacité à capturer l'information sémantique.

Le rapport est structuré comme suit. Nous présentons d'abord les données utilisées ainsi que leur analyse. Nous décrivons ensuite les différentes méthodes de modélisation mises en œuvre, accompagnées de leurs résultats respectifs. Une comparaison globale des modèles est ensuite proposée, avant de discuter des limites du projet et des pistes d'amélioration possibles.

2 Données

2.1 Construction et description du corpus

Le corpus utilisé dans ce projet repose sur deux sources de données complémentaires. D'une part, un fichier de méta-données contenant des informations structurées sur les documents (prénom du titulaire, partis politiques, etc.). D'autre part, les textes associés à ces méta-données qui ont été préalablement collectés.

Cependant, la variable indiquant le parti politique n'était pas directement exploitable pour une tâche de classification supervisée. En effet, le nombre de partis présents dans les données est important et leur granularité ne correspond pas à l'objectif du projet. Un mapping a ainsi été construit afin d'associer chaque parti politique à une orientation idéologique parmi trois classes : *gauche*, *centre* et *droite*.

À l'issue de ce processus, le jeu de données final est composé de textes politiques accompagnés de leur label d'orientation idéologique. Ce corpus constitue la base des analyses exploratoires et des expérimentations de modélisation présentées dans la suite du rapport.

2.2 Analyse descriptive

Une analyse de la variable cible a été réalisée afin d'examiner la répartition des observations. La Figure 1 présente le nombre de textes par classe d'orientation politique.

Cette figure met en évidence un déséquilibre entre les classes. Cet aspect devra être pris en compte lors de la modélisation, car il peut influencer l'apprentissage des modèles, certains labels étant susceptibles d'être mieux prédits que d'autres.

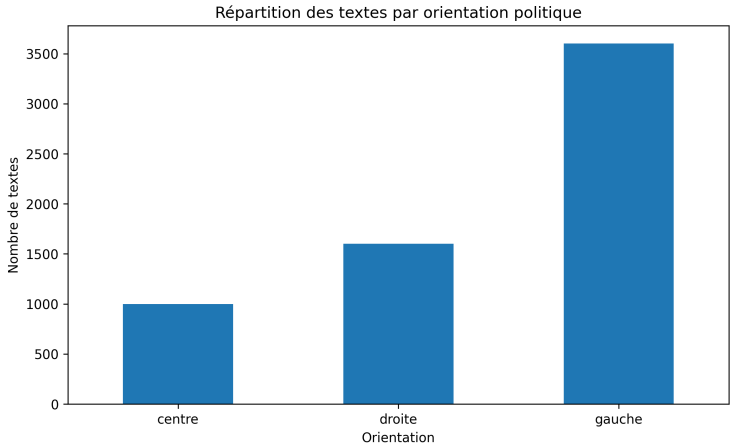

Figure 1: Répartition des textes par orientation politique.

Afin de mieux caractériser le corpus, quatre variables de longueur ont été construites à partir du texte, correspondant au nombre de caractères, de mots, de phrases et de tokens. Le nombre de tokens a été calculé à l'aide du modèle `fr_core_news_sm` de spaCy, ce qui permet d'obtenir une mesure plus adaptée aux futurs modèles de NLP que le simple comptage de mots.

La Figure 2 montre la distribution du nombre de tokens par document.

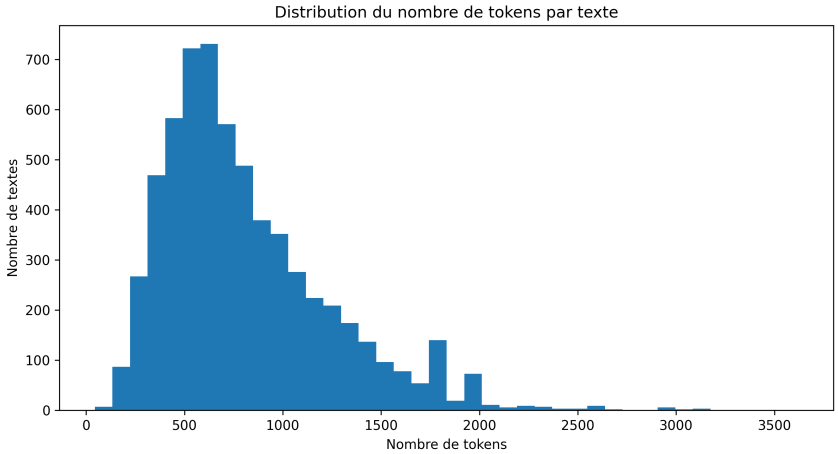

Figure 2: Distribution du nombre de tokens par texte.

Cette distribution permet d'évaluer l'hétérogénéité du corpus. Dans notre cas, les textes présentent des longueurs variables, ce qui constitue un enjeu pour la modélisation. En effet, certains modèles étant limités en nombre de tokens, il est nécessaire d'adapter les méthodes afin de pouvoir traiter efficacement les documents les plus longs.

Au-delà de la distribution globale, il est également intéressant de comparer la longueur des textes selon la classe idéologique. La Figure 3 présente un boxplot du nombre de tokens par orientation politique.

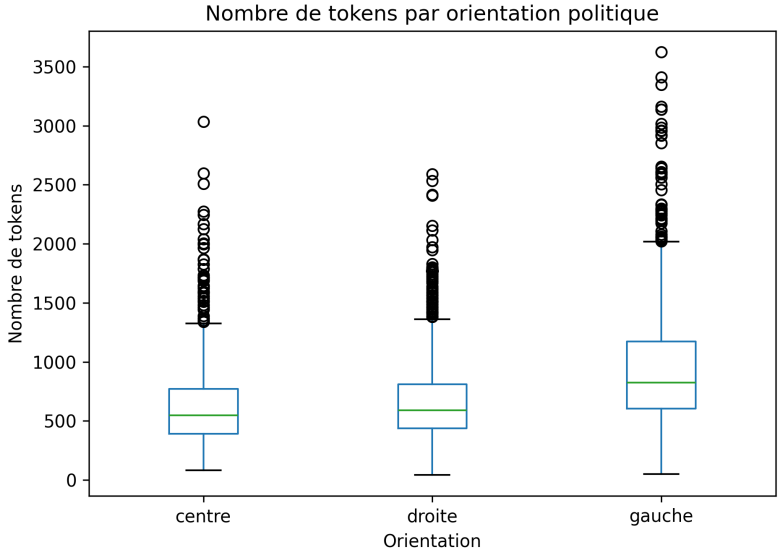

Figure 3: Distribution du nombre de tokens selon l'orientation politique.

Ce graphique montre que les textes labellisés comme appartenant à la gauche ont tendance à contenir un plus grand nombre de tokens. Cette observation est importante car des différences de longueur entre les classes peuvent influencer les performances des modèles. En effet, un modèle peut apprendre indirectement des caractéristiques liées à la structure des textes plutôt qu'à leur contenu idéologique proprement dit.

2.3 Analyse lexicale exploratoire

Une dernière analyse exploratoire a consisté à extraire les mots les plus fréquents pour chaque orientation politique. Pour cela, les textes ont été normalisés (passage en minuscules, suppression des accents et de la ponctuation) puis filtrés à l'aide d'une liste de mots outils (*stopwords*) afin de conserver principalement les termes porteurs de sens.

Les Figures 4, 5 et 6 montrent les quinze mots les plus fréquents pour chacune des classes.

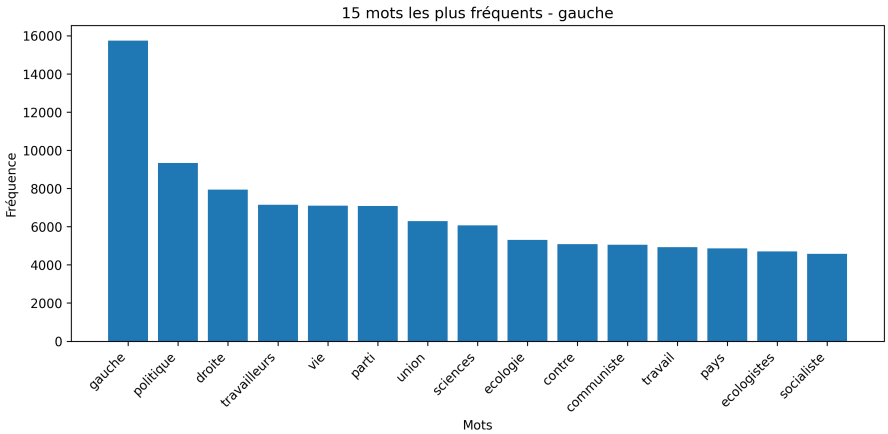

Figure 4: Top 15 des mots les plus fréquents pour la classe *gauche*.

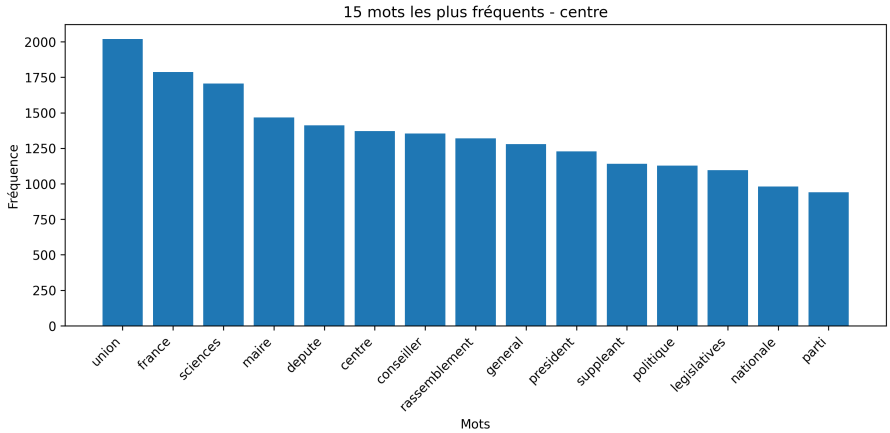

Figure 5: Top 15 des mots les plus fréquents pour la classe *centre*.

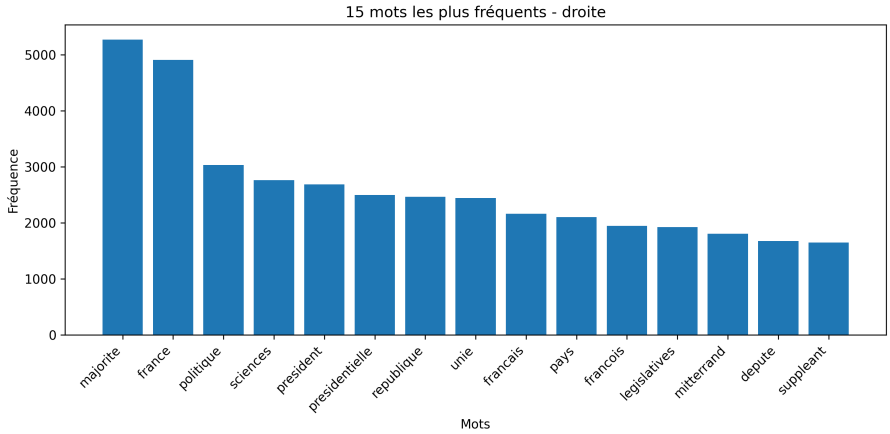

Figure 6: Top 15 des mots les plus fréquents pour la classe *droite*.

Cette analyse lexicale ne constitue pas une méthode de classification en soi, mais elle permet d'obtenir une première intuition sur les différences de vocabulaire entre les classes. Certains termes apparaissent plus caractéristiques de certaines orientations, ce qui suggère qu'une partie de l'information nécessaire à la classification est bien présente dans le contenu lexical des documents.

2.4 Synthèse

L'analyse exploratoire met en évidence deux éléments importants. Premièrement, les textes présentent des longueurs variables, parfois importantes, ce qui constitue un enjeu méthodologique central pour le choix des modèles. Enfin, l'étude des mots les plus fréquents suggère l'existence de différences lexicales entre les orientations politiques, ce qui rend la tâche de classification pertinente du point de vue du NLP.

Ces observations justifient les choix de modélisation présentés dans la section suivante, où plusieurs approches seront comparées afin d'évaluer leur capacité à capturer l'information discriminante contenue dans les textes.

3 Modélisation

Dans cette section, nous présentons les différentes approches de modélisation mises en œuvre pour la classification des textes politiques. Trois méthodes ont été explorées, allant d'une approche classique basée sur TF-IDF à des représentations vectorielles plus avancées avec Doc2Vec et SBERT. Chaque modèle est évalué à l'aide des mêmes métriques afin de permettre une comparaison cohérente.

3.1 TF-IDF + LinearSVC

3.1.1 Principe

La première approche repose sur une représentation classique des textes à l'aide de la méthode TF-IDF (*Term Frequency - Inverse Document Frequency*). Cette technique consiste à représenter chaque document sous forme de vecteur en pondérant les termes selon leur fréquence dans le document et leur rareté dans le corpus. Cela permet de mettre en évidence les mots les plus informatifs. Ces vecteurs sont ensuite utilisés comme variables d'entrée d'un classifieur `LinearSVC`, un modèle linéaire qui apprend à discriminer les classes à partir de ces représentations. Dans ce projet, il est utilisé pour effectuer une classification trinaire, en assignant à chaque document une orientation politique parmi *gauche*, *centre* ou *droite*.

3.1.2 Résultats

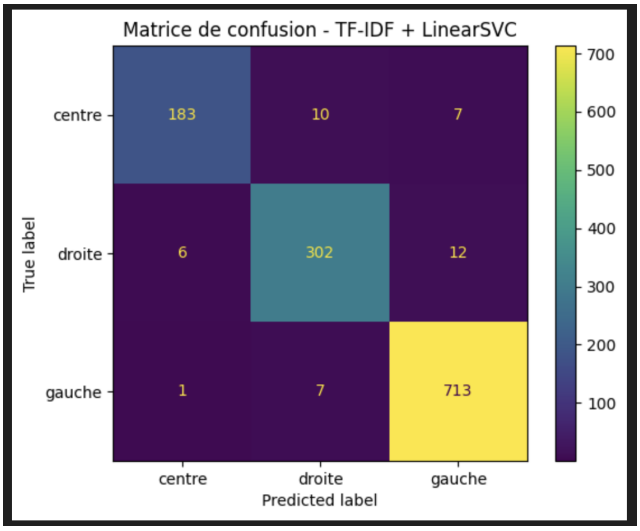

Figure 7: Matrice de confusion pour le modèle TF-IDF + LinearSVC.

Les performances du modèle sur l'ensemble de test sont les suivantes :

- Accuracy : 0.965
- F1-score macro : 0.955

On observe que ce modèle obtient d'excellentes performances globales. La classe *gauche* est particulièrement bien prédite, avec un taux de bonne classification de 98.9%, ce qui en fait la classe la plus facilement identifiable. La classe *droite* obtient également de très bonnes performances avec 94.4% de prédictions correctes, tandis que la classe *centre* atteint 91.5%.

3.1.3 Analyse

Ces résultats montrent que l'approche TF-IDF, bien que relativement simple, constitue une baseline particulièrement performante pour cette tâche. Cette efficacité s'explique notamment par le fait que la classification repose en grande partie sur des différences lexicales marquées entre les classes, certains termes étant fortement associés à une orientation politique donnée. En mettant en avant les mots les plus discriminants grâce à sa pondération, TF-IDF permet ainsi de capturer efficacement ces signaux.

Cependant, cette méthode reste limitée, car elle ne capture pas les relations sémantiques entre les mots et ne prend pas en compte le contexte global du texte.

3.2 Doc2Vec + LinearSVC

3.2.1 Principe

La deuxième approche repose sur le modèle Doc2Vec, qui permet d'obtenir une représentation dense des documents en capturant des relations sémantiques globales. Contrairement à TF-IDF, qui repose uniquement sur la fréquence des mots, Doc2Vec apprend des vecteurs continus en tenant compte du contexte dans lequel les mots apparaissent. Chaque document est ainsi projeté dans un espace vectoriel latent où des textes sémantiquement proches ont des représentations similaires.

Les vecteurs ainsi construits sont ensuite utilisés comme variables d'entrée du même classifieur `LinearSVC` que celui employé avec TF-IDF.

3.2.2 Résultats

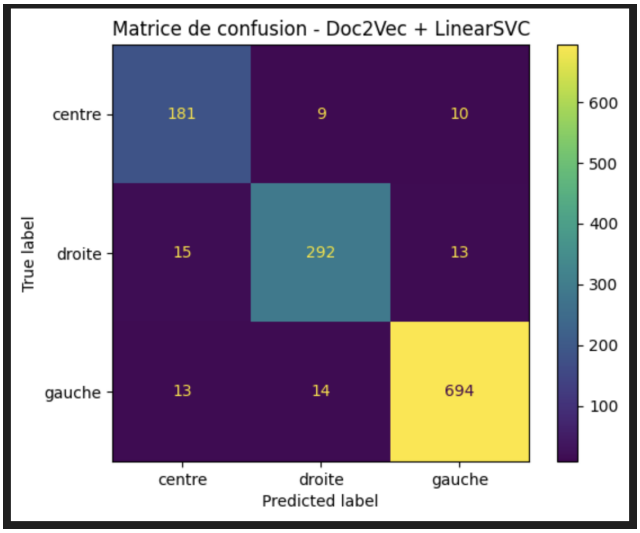

Figure 8: Matrice de confusion pour le modèle Doc2Vec + LinearSVC.

Les performances du modèle sur l'ensemble de test sont les suivantes :

- Accuracy : 0.940
- F1-score macro : 0.923

Les résultats montrent de bonnes performances globales, bien que légèrement inférieures à celles obtenues avec TF-IDF. La classe *gauche* reste la mieux prédite, avec un taux de bonne classification de 96.3%. Les classes *centre* et *droite* obtiennent des performances plus modestes, avec respectivement 90.5% et 91.3% de prédictions correctes.

3.2.3 Analyse

Le modèle Doc2Vec permet de capturer une information sémantique plus riche que TF-IDF, en tenant compte du contexte global des mots et en produisant des représentations denses des documents. Toutefois, dans ce cas précis, cette richesse ne se traduit pas par de meilleures performances en classification.

Une explication tient à la nature de la tâche. La classification d'orientation politique semble reposer en grande partie sur des indices lexicaux spécifiques, tels que certains termes ou expressions fortement associés à une classe donnée. Ces signaux sont directement exploités par TF-IDF, qui met en avant les mots les plus discriminants, tandis que Doc2Vec tend à lisser ces différences en produisant des représentations plus globales et moins sensibles à la présence de mots clés précis.

3.3 SBERT + LinearSVC

3.3.1 Principe

La troisième approche repose sur l'utilisation d'embeddings issus du modèle SBERT (*Sentence-BERT*), qui permet d'obtenir des représentations vectorielles contextualisées des textes. Contrairement aux méthodes précédentes, SBERT s'appuie sur des modèles de type Transformer pré-entraînés, capables de capturer des relations sémantiques fines en tenant compte du contexte global dans lequel apparaissent les mots.

Plus précisément, SBERT projette les phrases dans un espace vectoriel dense de telle sorte que des textes sémantiquement proches soient représentés par des vecteurs proches.

Avec cette méthode, la longueur des documents constitue une contrainte importante car le modèle SBERT est limité à un maximum de 512 tokens en entrée. Afin de contourner cette limitation, les textes ont été découpés en segments de taille compatible avec cette contrainte. Un embedding est ensuite calculé pour chaque segment, puis ces représentations sont agrégées (par moyenne pondérée) afin d'obtenir un vecteur unique représentant l'ensemble du document.

Puis, comme pour les approches précédentes, ces vecteurs sont ensuite utilisés comme variables d'entrée du classifieur `LinearSVC`.

3.3.2 Résultats

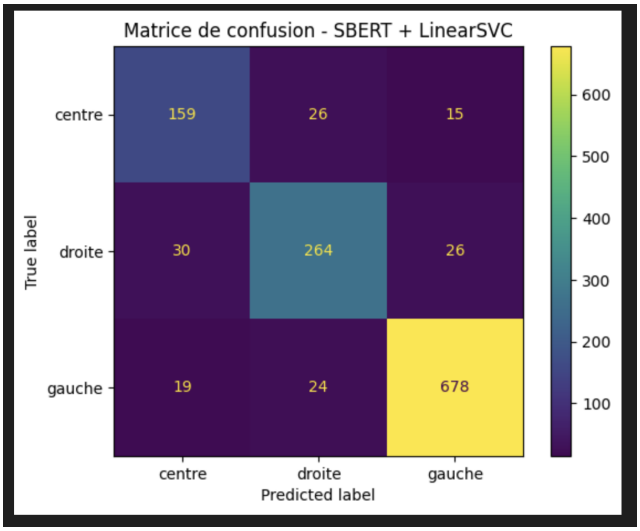

Figure 9: Matrice de confusion pour le modèle SBERT + LinearSVC.

Les performances du modèle sur l'ensemble de test sont les suivantes :

- Accuracy : 0.89
- F1-score macro : 0.85

Les résultats sont corrects mais inférieurs à ceux des modèles précédents. La classe *gauche* est prédite avec un taux de 94.0%, tandis que les classes *centre* et *droite* atteignent respectivement 79.5% et 82.5% de bonnes prédictions.

On observe davantage de confusions entre les classes, en particulier entre *centre* et *droite*, ce qui suggère que leurs représentations sont moins bien séparées dans l'espace vectoriel produit par SBERT.

3.3.3 Analyse

Bien que SBERT fournisse des représentations sémantiques riches, ses performances sont ici en retrait. Cela peut s'expliquer par plusieurs facteurs, notamment la nécessité de découper les textes longs, ce qui peut entraîner une perte d'information contextuelle.

De plus, l'agrégation des embeddings peut lisser certaines distinctions importantes entre les classes, rendant la classification plus difficile.

3.4 Comparaison des modèles

Afin de comparer les différentes approches, le Tableau 1 présente les performances des trois modèles étudiés.

Modèle	**Accuracy**	**F1-score macro**
TF-IDF + LinearSVC	0.965	0.955
Doc2Vec + LinearSVC	0.940	0.923
SBERT + LinearSVC	0.890	0.850

Table 1: Comparaison des performances des modèles

L'analyse des résultats met en évidence des différences significatives entre les approches. Le modèle TF-IDF associé à un classifieur linéaire obtient les meilleures performances, avec une accuracy de 96.5% et un F1-score macro de 95.5%. Ce résultat montre que, malgré sa simplicité, cette approche est particulièrement adaptée à la tâche étudiée.

Cette performance s'explique principalement par la nature du problème. La classification des textes politiques repose en grande partie sur des indices lexicaux explicites, tels que certains mots ou expressions caractéristiques d'une orientation idéologique. La représentation TF-IDF, qui met en avant les termes les plus discriminants, permet de capturer efficacement ces signaux. Le classifieur linéaire est alors suffisant pour séparer les classes dans cet espace de représentation.

À l'inverse, les modèles Doc2Vec et SBERT, bien qu'ils produisent des représentations sémantiques plus riches, n'apportent pas d'amélioration des performances. Dans le cas de Doc2Vec, l'apprentissage non supervisé des embeddings ne garantit pas que les vecteurs obtenus soient optimisés pour la tâche de classification, ce qui peut limiter leur pouvoir discriminant. De plus, la représentation dense tend à lisser les différences lexicales entre les documents.

Concernant SBERT, plusieurs facteurs peuvent expliquer les performances plus faibles. La nécessité de découper les textes peut entraîner une perte d'information contextuelle. Par ailleurs, l'agrégation des embeddings peut atténuer certaines distinctions importantes entre les classes. Enfin, bien que SBERT capture des relations sémantiques fines, celles-ci ne semblent pas être les plus pertinentes pour discriminer les orientations politiques dans ce corpus.

Enfin, on observe que les modèles les plus complexes ne sont pas nécessairement les plus performants dans ce contexte. Cela souligne l'importance d'adapter le choix des méthodes à la nature des données et de la tâche, plutôt que de privilégier systématiquement des approches plus avancées.

4 Limites et améliorations possibles

Malgré des résultats satisfaisants, ce projet présente plusieurs limites qui ouvrent également la voie à des pistes d'amélioration.

4.1 Construction des labels

Tout d'abord, la construction de la variable cible repose sur un mapping manuel des partis politiques vers trois catégories idéologiques (*gauche*, *centre*, *droite*). Or, il est difficile de réduire l'ensemble des partis politiques existants à seulement trois groupes, ce qui rend cette simplification nécessairement approximative et sujette à erreur. Certaines affiliations peuvent être ambiguës ou se situer à la frontière entre plusieurs orientations, rendant leur catégorisation délicate. De plus, un certain nombre de partis n'ont pas pu être clairement identifiés ou associés à une orientation, ce qui a conduit à exclure une partie des données et à réduire la diversité du corpus.

Une amélioration possible consisterait à affiner cette labellisation, par exemple en introduisant davantage de classes ou des sous-catégories idéologiques, afin de mieux refléter la complexité du paysage politique et d'améliorer la qualité des données d'apprentissage.

4.2 Déséquilibre du corpus

Par ailleurs, le jeu de données présente un déséquilibre entre les classes, notamment en faveur de la classe *gauche*. Bien que ce déséquilibre ait été pris en compte grâce à une stratification lors de l'entraînement, il a pu influencer les performances des modèles, qui apparaissent globalement plus efficaces pour identifier les textes de gauche. Un enrichissement des classes sous-représentées (*centre* et *droite*) permettrait d'obtenir une meilleure répartition des données, ce qui pourrait ensuite améliorer les performances des modèles sur ces catégories et réduire les biais d'apprentissage.

4.3 Temps de calcul

En outre, le temps de calcul nécessaire à l'entraînement des modèles, en particulier pour les approches les plus complexes, a constitué une contrainte importante. Cela a limité l'exploration des hyperparamètres lors des phases de validation croisée.

Ces différentes limites et perspectives montrent que, bien que les résultats obtenus soient satisfaisants, plusieurs leviers peuvent encore être exploités afin d'améliorer les performances et la robustesse du système de classification.

5 Conclusion

Dans ce projet, nous avons étudié la classification automatique de textes politiques selon leur orientation idéologique (*gauche*, *centre*, *droite*) en comparant plusieurs approches issues du traitement automatique du langage naturel.

Les résultats obtenus montrent que le modèle TF-IDF associé à un classifieur linéaire constitue la solution la plus performante dans ce contexte, surpassant les approches basées sur Doc2Vec et SBERT. Ce résultat souligne que, pour cette tâche, les différences lexicales entre les classes jouent un rôle central et peuvent être efficacement exploitées par des méthodes simples. À l'inverse, les modèles produisant des représentations sémantiques plus complexes n'apportent pas nécessairement un gain de performance, notamment en raison de la nature du problème et des contraintes liées aux données.

L'analyse des résultats a également mis en évidence plusieurs enjeux importants, tels que la gestion des textes longs, le déséquilibre des classes ou encore la qualité de la labellisation. Ces éléments ont un impact direct sur les performances des modèles et doivent être pris en compte dans la classification de textes politiques.

Enfin, ce travail montre qu'il est essentiel d'adapter le choix des méthodes à la nature des données et de la tâche étudiée. Des modèles plus complexes ne sont pas systématiquement synonymes de meilleures performances, et une approche simple mais bien adaptée peut s'avérer particulièrement efficace.

Des améliorations restent néanmoins possibles, notamment en enrichissant les données, en affinant la labellisation ou en explorant d'autres modèles. Ces perspectives ouvrent la voie à des travaux futurs visant à améliorer la robustesse et la généralisation des modèles de classification de textes politiques.

Références

[1] Ramos, J. (2003) Using TF-IDF to determine word relevance in document queries. In *Proceedings of the First Instructional Conference on Machine Learning*.

[2] Le, Q. & Mikolov, T. (2014) Distributed representations of sentences and documents. In *Proceedings of the 31st International Conference on Machine Learning (ICML)*, pp. 1188–1196.

[3] Reimers, N. & Gurevych, I. (2019) Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pp. 3982–3992.

[4] Beltagy, I., Peters, M.E. & Cohan, A. (2020) Longformer: The long-document transformer. arXiv preprint arXiv:2004.05150.